

MACHINE LEARNING

TRÌNH BÀY BÀI BÁO:

**GIÁ TRỊ SHAPLEY CHÍNH XÁC
ĐỂ GIẢI THÍCH MÔ HÌNH CÂY**

NHÓM 8

23127296 - Nguyễn Thành Luân


23127302 - Trần Quang Phúc

23127539 - Nguyễn Thanh Tiến

23127543 - Vũ Văn Vũ

GIỚI THIỆU

CÁCH NÀO ĐỂ ĐÁNH GIÁ MỘT MÔ HÌNH AI



- Shapley Value (SV) là một công cụ hiệu quả để diễn giải một model ai.
- Hiện nay, phương pháp áp dụng shapely tân tiến nhất vẫn còn xử lý sai các biến hạng mục, và tồn tại độ bias cao

TỔNG QUAN CÁC ĐÓNG GÓP

Nhóm nghiên cứu tập trung vào phương pháp tính giá trị Shapely cho cây quyết định:

- Một phương pháp xấp xỉ giá trị Shapely với độ chính xác cao hơn hiện tại

- Bác bỏ phương pháp tính SV bằng cách lấy tổng biến phân loại sau chuyển mã. Và chỉ ra giải pháp tốt

CÁC CÔNG TRÌNH LIÊN QUAN

TỔNG QUAN

- Partial Dependence Plot (PDP): xét tính quan trọng của biến ở mức toàn cục
- Individual Conditional Expectation (ICE): hiển thị đường dự đoán cho từng quan sát riêng lẻ khi một biến thay đổi
- Local Surrogate (LIME): Đơn giản hóa model , tập trung xung quanh biến cần xét, gần chính xác nhưng không ổn định

TỔNG QUAN

- Giá trị Shapely có tính chính xác và ổn định, đưa ra được đánh giá toàn cục và cục bộ. Nhưng việc tính toán đúng trị Shapely là rất khó khăn
- TreeSHAP: phương pháp tiên tiến nhất , tính toán trị shapely cho các cây quyết định. Tận dụng cấu trúc của cây quyết định để tính toán hiệu quả.


ĐỊNH VỊ

Chỉ tập trung vào giá trị shapley trên cây, là bản cải tiến trực tiếp của TReeSHAP

- Về vấn đề phụ thuộc: Bài báo giới thiệu hai bộ ước tính mới (Discrete và Leaf-based) có nền tảng thống kê
- Về vấn đề biến hạng mục: sử dụng khái niệm “liên minh”, đảm bảo rằng việc mã hóa biến không làm thay đổi hay sai lệch kết quả giải thích.

KIẾN THỨC NỀN TẢNG

DECISION TREE



- Là một kiểu mô hình dự báo
- Mỗi một nút trong (internal node) tương ứng với một biến
- Mỗi nút lá đại diện cho giá trị dự đoán của biến mục tiêu

BIẾN PHÂN LOẠI

- Có hai nhóm chính là biến định tính và biến định lượng (quantitative variables)
- Biến định tính có giá trị thuộc một tập hợp, ví dụ màu sắc $\in \{\text{đen, nâu, đỏ, cam, vàng, lục, lam, tím, xám, trắng, hoàng kim, bạc}\}$
- Biến định lượng thì sẽ biểu diễn được ở dạng một số cụ thể có thể áp dụng các toán tử cơ bản được.

GIÁ TRỊ SHAPLEY

- Phân phối cả lợi nhuận và chi phí một cách công bằng. Ý tưởng cốt lõi là phân tích hành vi của mô hình bằng cách loại bỏ các biến và xem xét các "hàm dự đoán rút gọn" (reduced predictors)

$$f_S(\mathbf{x}_S) \triangleq E_{Q_{S,\mathbf{x}}} [f(\mathbf{x}_S, \mathbf{X}_{\bar{S}})], \quad (1)$$

PHƯƠNG PHÁP NGHIÊN CỨU

TÍNH BẤT BIẾN CỦA SV VỚI CÁC BIẾN LIÊN TỤC SAU BIẾN ĐỔI

Proposition IV.1. Cho f và hàm tái tham số hóa của nó $\tilde{f} = f \circ \varphi^{(-1)}$, ta có $\forall i \in \llbracket 1, p \rrbracket$, và $U = \varphi(X)$:

$$\phi_{X_i}(f) = \phi_{U_i}(\tilde{f}). \quad (1)$$

BẤT BIẾN CỦA SV ĐỐI VỚI CÁC BIẾN PHÂN LOẠI ĐƯỢC MÃ HÓA

Proposition IV.2. Cho một hàm dự báo $f : \mathbb{R} \times \{1, \dots, K\} \rightarrow \mathbb{R}$ và hàm tái tham số hóa của nó $\tilde{f}$ sử dụng Dummy Encoding $\tilde{f} : \mathbb{R} \times \{0, 1\}^{K-1} \rightarrow \mathbb{R}$ sao cho $f(X, Z) \triangleq \tilde{f}(X, Z_1, \dots, Z_{K-1})$, ta có:

$$\begin{cases} \phi_{Z_{1:K-1}}(\tilde{f}) &= \phi_Z(f) \\ \phi_X(\tilde{f}; Z_{1:K-1}) &= \phi_X(f), \end{cases} \quad (2)$$

THUẬT TOÁN TREE SHAP

- Đi từ node gốc tới node lá.
- Tính đóng góp của biến tại mỗi node xét trong mọi tổ hợp của biến.
- Lặp lại với mọi cây trong rừng.
- Lấy trung bình có trọng số để ra được Shapley Value của biến.

VẤN ĐỀ VỚI TREE SHAP CHUẨN

Sử dụng giả định độc lập giữa các biến

=> nếu các biến có tương quan, việc tính toán Shapley Values sai lệch. Vì vậy thuật toán Tree SHAP phụ thuộc vào đường đi được đề xuất.

VẤN ĐỀ VỚI TREE SHAP PHỤ THUỘC VÀO ĐƯỜNG ĐI TỪ GÓC NHÌN CỦA BÀI BÁO

Thuật toán giả định rằng đường đi từ gốc đến lá là một xích Markov với phương trình sau:

$$P_X^{SHAP} \left(\prod_{k=1}^{d_m} I_{N_k} | \mathbf{X}_S = \mathbf{x}_S \right) = \delta_S(N_1) \times \prod_{i=2 | N_i \notin S}^{d_m} P \left(X_{N_i} \in I_{N_i} \middle| \prod_{k=2 | N_k \notin S}^i X_{N_{k-1}} \in I_{N_{k-1}} \right) \quad (9)$$

Nhóm nghiên cứu cho rằng giả định này không đúng trong tổng quát và sẽ làm cho Shapley Values bị sai lệch.

ĐỀ XUẤT 1: ƯỚC LƯỢNG RỜI RẠC

Trường hợp các biến là rời rạc: khi đó ta có công thức tính xác suất có điều kiện sử dụng thống kê

$$\hat{P}_X^{(D)}(L_m | X_S = \mathbf{x}_S) \triangleq \frac{N(L_m, \mathbf{x}_S)}{N(\mathbf{x}_S)}.$$

ĐỀ XUẤT 1: ƯỚC LƯỢNG RỜI RẠC

Đối với biến liên tục, nhóm nghiên cứu đề xuất phương pháp rời rạc hóa theo phân vị, khi đó biến X được mã hóa thành tập các biến có giá trị nhị phân và xác suất vẫn được tính theo công thức:

$$\hat{P}_X^{(D)}(L_m | X_S = \mathbf{x}_S) \triangleq \frac{N(L_m, \mathbf{x}_S)}{N(\mathbf{x}_S)}.$$

ĐỀ XUẤT 1: ƯỚC LƯỢNG RỜI RẠC

Khi đó hàm ước lượng rời rạc được định nghĩa như sau:

$$\hat{f}_S^D(\mathbf{x}_S) = \sum_{m \in C(S, \mathbf{x})} f_m \hat{P}_X^{(D)}(L_m | \mathbf{x}_S)$$

ĐỀ XUẤT 2: ƯỚC LƯỢNG LÁ

Công thức ước lượng xác suất có điều kiện

$$\hat{P}_X^{(Leaf)}(L_m | X_S \in L_m^S) = \frac{N(L_m)}{N(L_m^S)}$$

ĐỀ XUẤT 2: ƯỚC LƯỢNG LÁ

Khi đó hàm ước lượng lá được định nghĩa như sau:

$$\hat{f}_S^{(Leaf)}(\mathbf{x}_S) = \frac{1}{Z(S, \mathbf{x})} \sum_{m \in C(S, \mathbf{x})} f_m \hat{P}_X^{(Leaf)} \left(L_m \mid \mathbf{X}_S \in L_m^S \right)$$

với hằng số chuẩn hóa như sau:

$$Z(S, \mathbf{x}) = \sum_{m \in C(S, \mathbf{x})} \frac{N(L_m)}{N(L_m^S)}.$$

TÍNH TOÁN NHANH SHAPLEY VALUES DÙNG ƯỚC LƯỢNG LÁ

Proposition IV.4. Giả sử $f(x) = \sum_{m=1}^M f_m \mathbf{1}_{L_m}(x)$ là một mô hình dựa trên cây và $X = (X_1, \dots, X_p)$. Ta định nghĩa tập các biến $S_m = \{X_{N_1}, X_{N_2}, \dots, X_{N_{d_m}}\}$ trên đường đi của mỗi lá L_m .

Với bất kỳ biến X_i , Shapley Value $\varphi_i(f^{(\text{Leaf})}, x)$ có thể được phân rã thành tổng của M đóng góp được xác định trên mỗi lá L_m , và ta có:

$$\varphi_i(f^{(\text{Leaf})}, x) = \sum_{m=1}^M \varphi_i^m(f^{(\text{Leaf})}, x),$$

trong đó Shapley Value $\varphi_i^m(f^{(\text{Leaf})}, x)$ có các người chơi là các lá tương thích trong S_m và hàm giá trị:

$$v(f^{(\text{Leaf})}, S) = \mathbb{P}_X(L_m \mid X_S \in L_m^S(x)).$$

SO SÁNH ƯỚC LƯỢNG LÁ VÀ TREE SHAP

	Ước lượng lá	Tree SHAP
Độ phức tạp thời gian	$O(p \times M \times 2^D)$	$O(M \times D^2)$

trong đó:

- p là số lượng đặc trưng.
- M là số mẫu dữ liệu.
- D là độ sâu của cây.

THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

SỬ DỤNG MÔ HÌNH CHO CẢ 2 THÍ NGHIỆM

- Sử dụng mô hình Gaussian $X \sim N(\mu, \Sigma)$ để tính kỳ vọng có điều kiện chính xác.
- Tránh so sánh với KernelSHAP vì mục tiêu chính là cải thiện TreeSHAP – phương pháp hàng đầu cho mô hình cây
- KernelSHAP chủ yếu dựa trên phân phối biên và hướng tới mô hình-agnostic.

SỬ DỤNG MÔ HÌNH CHO CẢ 2 THÍ NGHIỆM

- Do biết phân phối X , có thể tính Shapley Values (SV) bằng Monte Carlo estimator.
- Kết quả MC được dùng làm giá trị gốc để so sánh với các ước lượng khác.

THÍ NGHIỆM 1

BỘ DỮ LIỆU

- Bao gồm $n = 10^4$ quan sát
- $X \in \mathbb{R}^p$ với $p = 5$ đặc trưng, theo phân phối Gaussian đa biến:
$$X \sim N(0, \Sigma), \Sigma = \rho \cdot J_p + (\rho - 1) \cdot I_p, \rho = 0.7$$
- Biến mục tiêu: $Y = B^T \cdot X$
- Tập trung vào dữ liệu liên tục

CHỈ SỐ ĐÁNH GIÁ VÀ MÔ HÌNH CHUẨN SO SÁNH

Chỉ số đánh giá:


- Relative Absolute Error (RAE): đo sai khác giữa SV ước lượng và SV thực
- True Positive Rate (TPR): kiểm tra thứ hạng k đặc trưng quan trọng nhất

Mô hình chuẩn so sánh:

- TreeSHAP: thuật toán chuẩn cho mô hình cây
- Leaf estimator: sử dụng kỳ vọng có điều kiện trong từng lá cây

SO SÁNH HIỆU SUẤT VÀ Ý NGHĨA THỐNG KÊ

- TreeSHAP có RAE trung bình = 3.31 và TPR = 86% ($\pm 17\%$), cho
- Thấy mức độ sai số lớn hơn và khả năng giữ nguyên thứ hạng top-k feature thấp hơn.
- Leaf estimator có RAE = 0.90 và TPR = 94% ($\pm 12\%$), chứng tỏ độ
- Chính xác cao hơn TreeSHAP, đặc biệt khi các đặc trưng có tương quan.



GIẢI THÍCH KẾT QUẢ

- TreeSHAP: những feature nằm ngoài path — sẽ bị bỏ qua khi tính giá trị đóng góp mặc dù các đặc trưng đó vẫn có thể có mối quan hệ hoặc ảnh hưởng đến đặc trưng đang xét, dẫn đến bị lệch (bias).
- Leaf estimator: không giả định các đặc trưng ngoài tập đang xét là độc lập, ít bị lệch hơn, đáng tin cậy hơn.

THÍ NGHIỆM 2

BỘ DỮ LIỆU


- Sử dụng lại mô hình giả lập từ Experiment 1.
- Tuy nhiên, có sự thay đổi tương quan giữa các đặc trưng ρ (0 đến 0.99), đại diện cho mức độ phụ thuộc ngày càng tăng giữa các đặc trưng.
- Thí nghiệm này tập trung dựa trên dữ liệu rời rạc

CHỈ SỐ ĐÁNH GIÁ VÀ MÔ HÌNH CHUẨN SO SÁNH


- Sử dụng chỉ số RAE và TPR để đánh giá, đồng thời lựa chọn TreeSHAP và Leaf estimator làm các mô hình so sánh.

SO SÁNH HIỆU SUẤT VÀ Ý NGHĨA THỐNG KÊ

- Ở mức tương quan thấp ($\rho \approx 0$), TreeSHAP hoạt động tốt, có giá trị R-MAE thấp
- Khi ρ tăng, nghĩa là các đặc trưng càng phụ thuộc lẫn nhau, Leaf estimator liên tục duy trì R-MAE thấp hơn TreeSHAP, cho thấy Leaf estimator ổn định hơn trong điều kiện đặc trưng phụ thuộc



SO SÁNH HIỆU SUẤT VÀ Ý NGHĨA THỐNG KÊ



GIẢI THÍCH KẾT QUẢ

- TreeSHAP: xem rằng các đặc trưng ngoài tập đặc trưng đang xét trên đường đi của cây là độc lập, do đó khi các đặc trưng thực sự phụ thuộc lẫn nhau (ρ cao), các ảnh hưởng từ đặc trưng bị bỏ qua, dẫn đến R-MAE tăng
- Leaf estimator: không yêu cầu giả định độc lập, nên vẫn giữ được hiệu quả khi các đặc trưng phụ thuộc lẫn nhau

KẾT LUẬN VÀ ĐỊNH HƯỚNG NGHIÊN CỨU TƯỞNG LAI

KẾT LUẬN

- Thiếu tin cậy do ước lượng bị sai lệch hoặc xử lý không phù hợp với biến phân loại
- Quá trình đánh giá thường dễ bị ảnh hưởng bởi thiên kiến xác nhận (confirmation bias)
- Giải thích bằng SV không phải là giải thích cục bộ (local), mà vẫn mang tính toàn cục (global), ngay cả trong mô hình tuyến tính đơn giản.

PROPOSITION 5.1

Proposition 5.1. *Let us assume that we have $X \in \mathbb{R}^p$, $X \in \mathcal{N}(0, I_p)$ independent Gaussian features, and a linear predictor f defined as:*

$$f(X) = (a_1X_1 + a_2X_2)\mathbb{1}_{X_5 \leq 0} + (a_3X_3 + a_4X_4)\mathbb{1}_{X_5 > 0}.$$

Even if we choose an observation $\mathbf{x}$ such that $x_5 \leq 0$ and the predictor only uses X_1, X_2 , the SV of ϕ_{X_3}, ϕ_{X_4} is not necessarily zero. Indeed, $\forall i \in \{3, 4\}$

$$\begin{aligned}\phi_{X_i} &= \frac{1}{p}P(\mathbf{X}_5 > 0) \sum_{S \subseteq [p] \setminus \{i, 5\}} \binom{p-1}{|S|}^{-1} \left(a_i(\mathbf{x}_i - E[\mathbf{X}_i]) \right) \\ &= K \left(a_i(\mathbf{x}_i - E[\mathbf{X}_i]) \right) \quad K \text{ a constant}\end{aligned}$$

ĐỊNH HƯỚNG NGHIÊN CỨU TƯỞNG LẠI

- Nghiên cứu các phương pháp thay thế SV mang lại giải thích thực sự cục bộ.
- Phát triển bộ chuẩn đánh giá hệ thống cho chất lượng giải thích trong AI
- Mở rộng phân tích sang mô hình phi tuyến và không gian chiều cao.



THANK YOU